过载上行 RSMA-MU-MIMO 系统中面向能量效率的多时间尺度在线学习与资源分配——模型与算法设计研究报告

研究工作组

2026 年 9 月 17 日

摘要

在 $K = 24$ 用户、$N_r = 16$ 天线的**过载**（$K > N_r$）上行速率分割多址（Rate-Splitting Multiple Access, RSMA）MIMO 系统中，能量效率（Energy Efficiency, EE）的在线最优化同时面临三重新挑战：分数型目标的非凸结构、长期交付/功率约束的耦合、以及 $K!$ 级组合解码顺序的不可枚举性。本报告给出一个以**随机最优控制**（Stochastic Optimal Control / 受约束 MDP）为表述、以**多时间尺度深度强化学习**为求解内核的完整建模与算法框架，并重点阐述三个可泛化到论文写作的算法构件：

(1) **Dinkelbach 参数化线性化**：将 EE 分数目标 $\max \bar{D}/\bar{P}_{\text{eff}}$ 依分数规划理论 [1] 等价化为带参数 $q^* \geq 0$ 的线性目标 $\Sigma D - q^* P_{\text{eff}}$。线性化不仅保留了最优解的等价性，更从**梯度方向**上根除了 $P \to 0$ 处 $\partial(\text{EE})/\partial P < 0$ 的奇点吸引子；q^* 由外层 Dinkelbach 迭代 (16) 在线更新。

(2) **Lyapunov 漂移-加-惩罚（drift-plus-penalty）软约束化**：将长期平均交付率约束（$\geq \delta$）与平均功率约束（$\leq \bar{P}$）用 **Neely 交付欠账虚拟队列** Y **与功率虚拟队列** X 吸收，化为" 虚拟队列稳定 $\Leftrightarrow$ 平均约束满足" 的公认标准形式；单时隙漂移-惩罚目标 (21) 经推导后即重构为 DGLCR 复合奖励——" 硬阈值" 由此获得严格的渐近合理性（$O(1/V)$ 最优性遗憾、$O(V)$ 违约界）。

(3) **Plackett-Luce 概率解码顺序**：把 MMSE-SIC 接收机中的解码顺序 $\pi \in \mathcal{S}_K$ 建模为连续偏好分数 $\mathbf{z}$ 上的 Plackett-Luce 分布，以 Gumbel-Top-K 实现与理论分布精确一致的单轮抽样，其解析对数似然 (25) 关于 $\mathbf{z}$ 完全可微，将" 组合决策" 无缝嵌入策略梯度——实现*逐时隙自适应 SIC 顺序*。

报告同时给出两级并行架构（每 $T_s = 20$ 时隙的慢尺度 Meta-Controller 负责分组与组级分割比；每时隙的 SA-GAT Worker 负责功率份额、drain 比例与解码顺序）、完整训练算法（算法 1）与最终模型综合（§4.9）。在 7 点 SNR 评估网格上，模型达到全部 7 个逐点达标门（score $[7, 0.9519, -8.3971, 1.0804]$），跨种子稳健（$\sigma \approx 0.005$），且预注册的消融微调无处理效应。所有公式与数值均以仓库代码（`src/`）与论文草稿（`docs/paper/`）为最终依据。

关键词：速率分割多址；能量效率；分数规划；Dinkelbach 变换；Lyapunov 漂移-加-惩罚；虚拟队列；Plackett-Luce；Gumbel-Top-K；多时间尺度强化学习

1 引言

1.1 问题背景

过载上行链路（活跃用户数 K 超过基站接收天线数 N_r）是 5G/6G 无线接入的典型工况。此时空间自由度不足以无失真分离所有用户，传统 SDMA 的性能受制于惩罚性的等效干扰；非正交多址（NOMA）以功率域复用换取部分增益，但其严格的解码规则与公平性折衷在异构 QoS 场景下并不总是最优。速率分割多址（RSMA）将各用户消息分裂为公共流与私有流，经由叠加编码与连续干扰消除（SIC）在速率域上柔性管理干扰，已被广泛证明在过载与混合 QoS 场景下优于 SDMA 与 NOMA[11]。

RSMA 发射机同时面对三类强耦合决策：(i) 公共/私有功率分割比（连续）；(ii) 逐用户发射功率分配（连续，受限总功率）；(iii) 接收机 SIC 解码顺序（$K!$ 级组合）。三者共同决定可达速率域 (4)–(5)，其联合最优在快衰落、信道估计不确定性（imperfect CSI）与突发流量下需要在无前瞻的在线场景中逐时隙求解——这正是经典集中式最优化的失效区间。

与此同时，能量效率（EE, bits/Joule）成为网络运营的核心指标。EE 的分数结构 D/P_{consume} 带来两重困难：其一，$P \to 0$ 处分数目标的梯度方向 $\partial(\text{EE})/\partial P < 0$，诱导所有以 EE 为奖励的学习器趋向” 几乎关机” 的退化解；其二，交付率（delivery）这类运营商级硬指标需要以**长期平均约束**而非启发式惩罚的形式嵌入模型，才能获得可证的性能保证。

1.2 方案与贡献

本方案的技术路线可概括为**三层转化**，各层均采用公开文献的成熟理论构件，从而为论文写作提供” 公认、可讲故事的” 建模口径（而非实现细节的镜像）：

1. **问题层（随机最优控制）**：将 EE 最大 + 多约束刻划为带长期平均约束的马尔可夫决策过程（受约束 MDP / CMDP），约束包括平均交付率下界、平均发射功率上界与队列稳定性。问题表述 (11) 完全标准，不含任何实现特设项（§3.5）。

2. **求解层（Lyapunov 漂移-加-惩罚 + Dinkelbach）**：分数目标经 Dinkelbach 线性化 (14)，平均约束经虚拟队列软约束化 (17)–(18)，所得单时隙代理目标在结构上精确等于 DGLCR 奖励（命题 4.5）——” 硬阈值 0.98 / 8 W” 由此获得虚拟队列这一标准理论身份，并附带 $O(1/V)$ 最优性保证（定理 4.4）。

3. **决策层（多时间尺度分层 DRL + Plackett-Luce）**：慢尺度（分组 g、组级分割比 α）与快尺度（功率份额、drain 比例、解码顺序）分层；解码顺序以 Plackett-Luce 连续偏好建模并保持梯度通道（命题 4.6）。

贡献整理为四点：

1. 过载 RSMA 场景的 EE 在线优化 **CMDP 建模**，含平均交付率/功率约束与队列稳定性的完整表述；

2. 分数 EE 的 **Dinkelbach 线性化**作为奖励信号（梯度级根除关机捷径），q^* 在线 Dinkelbach 迭代；

3. 交付/功率约束的 **Lyapunov 虚拟队列软约束化**与 DGLCR 复合奖励的结构一致性证明；

4. **Plackett-Luce 解码顺序**的概率模型与 Gumbel-Top-K 可微抽样通道，及完整的双层训练算法。

1.3 组织

§3 建立系统模型与随机最优控制问题；§4 给出算法设计, 其中 §4.2（Dinkelbach）、§4.3（Lyapunov 漂移-加-惩罚）、§4.5（Plackett-Luce）为核心构件, §4.9 给出最终模型综合；§5 报告评估协议与主要结果；§6 总结。

2 相关工作

分数规划与 EE 优化：Dinkelbach 算法 [1] 以参数化线性子问题序列求解 $\max N(x)/D(x)$，在凹-凸条件下享有线性/超线性收敛；[2] 将其系统应用于无线通信 EE 最大化。本文的采用点与前人不同：Dinkelbach 线性化被**嵌入奖励构造层**，为 DRL 提供处处方向正确的每时隙 EE 梯度，而非作为离线集中式求解器。

Lyapunov 随机网络优化：Neely[3] 的漂移-加-惩罚框架以虚拟队列把长期平均约束转化为稳定性条件，并给出 $[O(1/V), O(V)]$ 的最优性-违约权衡；[4, 5] 将之与 DRL 结合用于无线资源分配。本文的虚拟队列 Y, X、二次积压惩罚与自适应 V 均为该框架的标准实例（含有限缓冲修正，见 §4.3）。

组合决策的连续松弛：Plackett-Luce[6, 7] 是穷举级数据上标准的低秩排列概率模型；Gumbel-Top-K[8] 给出其无偏单轮抽样及对已实现排列的可微对数似然。本文以之承载 SIC 解码顺序，区别于文献中常用的启发式排序（如信道增益降序）。

分层强化学习：层级 HRL（option/慢快尺度抽象）[10] 与两时间尺度随机逼近的收敛性为慢-快两层策略分离提供理论支撑；受约束策略优化（如 CRPO[9]、Lagrangian 对偶）为可行性-最优性折衷提供统一语言。

3 系统模型与问题表述

3.1 网络与信道模型

单小区上行链路：基站配 $N_r = 16$ 根接收天线，服务 $K = 24$ 个用户（每用户 $N_t = 2$ 根发射天线），构成过载工况 $K > N_r$。每个 episode 含 $T = 200$ 时隙。用户 k 至基站距离 d_k 在每个 episode 初由 $[50, 300]$ m 采样并在 episode 内固定，遵循 3GPP UMi 路径损耗（指数 3.76，100 m 处归一为 0 dB，保留约 29 dB 远近差）。信道服从一阶 AR(1) 时间相关模型 (1)，强度相关性 $\rho = 0.9$。

导频辅助 MMSE 信道估计给出每用户误差方差 (2)：随噪声功率 σ^2 自适应且带平坦下限 $\varepsilon_{\text{floor}} = 0.01$。估计信道 $\hat{\mathbf{H}}$ 与实际信道 $\mathbf{H}$ 满足有界最坏情况误差 $\|\Delta\mathbf{h}_k\| \le \varepsilon$。训练期噪声功率按 $\sigma^2 \in [-5, 35]$ dB 逐 episode 域随机化（评估点为固定网格，见 §3.5.2）。

3.2 RSMA 传输与 MMSE-SIC 接收

用户 k 的消息分裂为公共部分（功率占比 $\alpha_k \in [\alpha_{\min}, \alpha_{\max}]$，$\alpha_{\min} = 0.1, \alpha_{\max} = 0.95$）与私有部分，发射信号为 (3)。同组的用户共享组内公共流（组号 g_k 见 §4.7）；所有公共流先于私有流解码，组内公共流 SIC 在同一组内执行。基站采用统一 MRT 发射权重 $\mathbf{W}_c, \mathbf{W}_p \in \mathbb{C}^{N_r \times K}$（按估计信道 $\hat{\mathbf{H}}$），逐用户功率上限 $P_k \le P_{k,\max} = 1.0\,\mathrm{W}$（总上限 24 W）。

接收端按解码顺序 $\pi = (\pi_1, \ldots, \pi_K)$ 执行两阶段 MMSE-SIC。定义 $\mathcal{D}_j$ 为在位置 j 之前已解码的流集合，则第 j 个被解码流的 SINR 为 (4)：分母收集 (i) 未解码流干扰，(ii) 已解码流经硬件残余 β^2 的 SIC 残余，(iii) 经 ε^2 的信道弥散残余，及 (iv) 热噪声。β（`sic_imperfection`）与 ε（CSI 误差界）为**独立物理参数**，分别刻画 SIC 硬件局限与信道估计质量，不可合并。速率计算为 (5)；声明速率用 $(\hat{\mathbf{H}}, \varepsilon)$，实际速率用 $(\mathbf{H}, \varepsilon{=}0)$，outage 感知速率取两者最小值，从而抑制过量声明。

$$h_k[t] = \rho\, h_k[t-1] + \sqrt{1-\rho^2}\,\Delta h_k[t], \quad \Delta h_k \sim \mathcal{CN}(\mathbf{0}, \sigma_h^2 \mathbf{I}), \tag{1}$$

$$\sigma_{\mathrm{est}}^2 = \frac{\sigma^2}{K\, p_{\mathrm{pilot}}} + \varepsilon_{\mathrm{floor}}^2, \tag{2}$$

$$x_k = \sqrt{\alpha_k p_k}\, s_k^c + \sqrt{(1-\alpha_k) p_k}\, s_k^p, \quad \mathbb{E}\,|s_k^c|^2 = \mathbb{E}\,|s_k^p|^2 = 1, \tag{3}$$

$$\mathrm{SINR}_k^{(j)} = \frac{p_k \left|\mathbf{w}^{\mathsf{H}} \hat{\mathbf{h}}_k\right|^2}{\sum_{i \notin \mathcal{D}_j} p_i \left|\mathbf{w}^{\mathsf{H}} \hat{\mathbf{h}}_i\right|^2 + \beta^2 \sum_{i \in \mathcal{D}_j} p_i \left|\mathbf{w}^{\mathsf{H}} \hat{\mathbf{h}}_i\right|^2 + \varepsilon^2 \sum_i p_i \|\mathbf{w}\|^2 + \sigma^2 \|\mathbf{w}\|^2}, \tag{4}$$

$$R_k = \log_2\!\big(1 + \mathrm{SINR}_k^c\big) + \log_2\!\big(1 + \mathrm{SINR}_k^p\big), \quad R_{\mathrm{sum}} = \sum_{k=1}^{K} R_k. \tag{5}$$

3.3 流量、队列与异构 QoS

到达过程：$A_k[t] \sim \mathsf{Poisson}(\lambda_k)$，平均到达率随 SNR 自适应 $\lambda(\mathrm{snr}) = \mathrm{load}(\mathrm{snr}) \cdot C(\mathrm{snr})/K$，$\mathrm{load}(\cdot)$ 为从 0.75（低 SNR）到 1.3（高 SNR）的 sigmoid（中点 15 dB，陡度 0.3），使系统在全 SNR 区间保持可观负载而不饱和。三档异构 QoS 类分别缩放到达率、Lyapunov 权重与溢出权重为 $(2.0, 1.0, 0.3)$、$(8.0, 1.0, 0.2)$、$(8.0, 1.0, 0.2)$。

有限缓冲队列模型：每个用户维护容量 $Q_{\max} = 100$ 比特的 FIFO 缓冲，队列演化与交付比特数分别为 (6) 与 (7)——其中 $d_k[t] \in [0, 1]$ 为 Worker 输出的排水（drain）比例，缓冲区满时新到达被丢弃并计入溢出 $O_k[t]$。episode 内交付率（delivery）定义为已到达比特中被成功服务比特之比例 (8)。在数学模型中，$Q_{\max}$ 是物理缓冲参数而非优化结构；其影响经由 (8) 直接进入评估指标，并在 §4.3 以二次积压成本显式内化。

$$Q_k[t+1] = \min\{\max\{Q_k[t] - D_k[t],\, 0\} + A_k[t],\; Q_{\max}\}, \tag{6}$$

$$D_k[t] = \min\{Q_k[t],\; d_k[t]\, R_k[t]\}, \tag{7}$$

$$\mathrm{deliv} = \frac{\sum_{k,t} D_k[t]}{\sum_{k,t} A_k[t]}. \tag{8}$$

3.4 功耗与能量效率

采用真实功耗模型：发射功率经 PA 效率 $\eta_{\mathrm{PA}} = 0.35$ 折损并叠加静态电路功耗 $P_{\mathrm{circ}} = 5.0\,\mathrm{W}$，

$$P_{\mathrm{consume}} = \frac{\sum_k P_k}{\eta_{\mathrm{PA}}} + P_{\mathrm{circ}}, \qquad P_{\mathrm{eff}} = \max\{P_{\mathrm{consume}},\, P_{\mathrm{floor}}\},\ \ P_{\mathrm{floor}} = 3.0\,\mathrm{W}. \tag{9}$$

静息功耗使 $P \to 0$ 时总功耗仍有 5 W 下界，EE 上界有限。本文以**服务类 EE**（delivery-weighted EE）作为统一指标与奖励口径，

$$\mathrm{EE}[t] = \frac{\sum_k D_k[t]}{P_{\mathrm{eff}}[t]}, \tag{10}$$

即单位有效功耗所服务的数据比特——与 (8) 同源，避免空队列时" 速率虚高、交付为零" 的激励偏差。

3.5 优化问题与评估口径

3.5.1 随机最优控制（CMDP）表述

记时隙决策元组 $\mathbf{x}[t] = (g, \alpha, \mathbf{p}, \mathbf{d}, \pi)[t] \in \mathcal{X}$，其中 $g \in \mathbb{R}^K$（分组）、$\alpha \in [\alpha_{\min}, \alpha_{\max}]^G$(组级分割比)、$\mathbf{p}$（功率份额）、$\mathbf{d} \in [0,1]^K$（drain）、$\pi \in \mathcal{S}_K$（SIC 排列空间）。系统寻求长期平均意义的约束最优策略：

$$\max_{\{\mathbf{x}[t]\}} \quad \liminf_{T\to\infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}\,\mathrm{EE}[t] \tag{11a}$$

$$\text{s.t.} \quad \liminf_{T\to\infty} \frac{1}{T} \sum_{t} \mathbb{E}\,\mathrm{deliv}[t] \ \geq\ \delta \ =\ 0.98, \tag{11b}$$

$$\limsup_{T\to\infty} \frac{1}{T} \sum_{t} \mathbb{E}\,\textstyle\sum_k P_k[t] \ \leq\ \bar{P} \ =\ 8\,\mathrm{W}, \tag{11c}$$

$$\overline{Q}_k < \infty \ \ \forall k \quad \text{(队列稳定性 / 平均缓冲有界)}, \tag{11d}$$

$$0 \leq p_k[t] \leq P_{k,\max}, \ \ \alpha_k[t] \in [\alpha_{\min}, \alpha_{\max}], \ \ d_k[t] \in [0,1], \ \ \pi[t] \in \mathcal{S}_K. \tag{11e}$$

(11b)–(11c) 为**长期平均约束**（time-average constraints），(11d) 为**率稳定**（rate stability）条件，(11e) 为动作域约束。关键结构事实：某一策略必须同时满足评估网格 (12) 上**每一点**的约束，因而 (11) 不可逐点分解——这正是该问题对逐点无关基线（如固定功率、无学习策略）的结构性壁垒。

3.5.2 评估协议（独立于模型的裁定口径）

评估在 7 点 SNR 网格 $\mathcal{S} = \{0, 5, \ldots, 30\}\,\mathrm{dB}$（训练范围 $[-5, 35]$，imperfect CSI）上进行，每点相对参考 SDMA 策略设立**两条相对门限**

$$\mathrm{deliv}_\pi(s) \geq \mathrm{deliv}_{\mathrm{SDMA}}(s), \qquad \mathrm{queue}_\pi(s) \leq 1.1 \cdot \mathrm{queue}_{\mathrm{SDMA}}(s), \ \ \forall s \in \mathcal{S}, \tag{12}$$

并按字典序聚合为 score = [#{达标点}, $\overline{\mathrm{deliv}}$, $-\overline{\mathrm{queue}}$, EE ratio]（达标点个数绝对优先）。全局聚合终止检查（mean EE > SDMA×1.05 且 mean power < SDMA）仅用于门控优化轮次终止，不替代 (12)。本小节为裁定口径，不参与模型构造——这保证了模型/算法章节的表述与实现的成败判据解耦。

4 算法设计

本节遵循统一叙述纪律：每一构件按「 问题 → 模型化（公认形式）→ 算法 → 与代理目标 (22) 的接线」四步展开。§4.2–§4.5 为核心构件。

4.1 总体框架：两级 POCMDP 与求解路线

将 (11) 求解为**两层**近似：慢尺度（每 $T_s = 20$ 时隙）Meta-Controller 决策分组与组级分割比 α（战略层，慢变）；快尺度（每时隙）Worker 决策功率份额、drain 与解码顺序（战术层，快变）。

- **观测（部分可观测性）**：策略不观测原始复信道 $\mathbf{H}$，仅观测其聚合统计——per-user 特征块（信道增益、队列、到达、功率/速率历史、干扰、QoS 类、组号、距离）+ 全局量（时隙占比、SNR、CSI 误差）；默认维度 $11K{+}3$，可选 $H = 4$ 时隙历史窗口（增量 $3H \cdot K$）。以 State-Augmentation[1] 注入对偶状态。故模型为**受约束的部分可观测 MDP**（POCMDP），由 DRL 端到端求解。
- **求解路线**：处理宪结构为三层的代理目标构造（图 1）：EE 分数目标 Dinkelbach 线性化（§4.2）→ 平均约束虚拟队列软约束化（§4.3）→ 组装为单时隙代理奖励 DGLCR（§4.4），并由双层 PPO 以 (29) 优化。解码顺序的 PL 建模（§4.5）为该路线的动作空间侧闭环。
- **问题 → 机制映射**：(11) 各元素与算法构件的对应关系见表 1，该表同时也是最终模型综合（§4.9）的索引。

表 1: (11) 的问题元素 → 算法机制映射（详读索引表）。

问题元素	数学表述	承载机制（构件）	在代理目标中的实现
EE 目标 11a	分数型 $\bar{D}/\bar{P}_{\text{eff}}$	Dinkelbach 线性化（§4.2）	$w_{\text{ee}}(\Sigma D - q^* P_{\text{eff}})$
交付率约束 11b	平均交付率 $\geq \delta$	交付虚拟队列 Y（§4.3）	$w_y\,(Y/Y_{\text{ref}})\,\Sigma D$ + 对偶 λ
功率约束 11c	平均功率 $\leq \bar{P}$	功率虚拟队列 X（§4.3）	$-w_x\,(X/X_{\text{ref}})\,P_{\text{tot}}$
队列稳定性 11d	$\bar{Q}_k < \infty$	二次积压成本 LDPTRLQ（§4.3）	$-w_q \Sigma Q_k^2/Q_{\max}^2 - w_{\text{ovf}} \Sigma O_k$
SIC 排列 11e	$\pi \in \mathcal{S}_K$	Plackett-Luce 偏好（§4.5）	$\pi \sim \mathsf{PL}(\mathbf{z})$, $\log P(\pi \mid \mathbf{z})$
慢尺度决策	分组 g、分割比 α	Meta-Controller（§4.7）	独立 PPO 目标 (27)

4.2 Dinkelbach 线性化 EE

问题：(11a) 是分数型目标。设 $U(P) = \sum_k D_k(P)$，则在低功率区

$$\frac{\partial}{\partial P}\Big(\frac{U(P)}{P_{\text{eff}}}\Big) \;=\; \frac{P_{\text{eff}}\,U'(P) - U(P)}{P_{\text{eff}}^2}, \tag{13}$$

[1]等维替换干扰/公平/距离三块观测为：Lagrangian 对偶值 λ 桶、交付欠账 Y、Dinkelbach 参数 q^*——观测维度不变而约束状态显式可见。

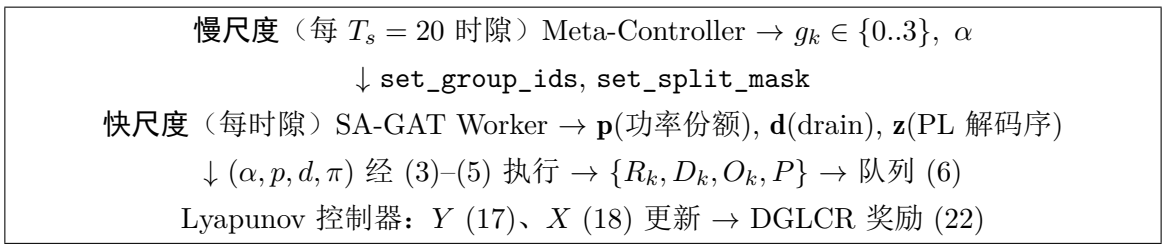


图 1: 多时间尺度决策与奖励闭环；虚拟队列 Y, X 将长期约束反馈到每时隙奖励。

其中 U' 在 log-陡峭段为正，但 $U(P)$ 与 P_{eff}（含 5 W 静息）的相对大小使分子为负：梯度**持续指向** $P \to 0$。该" 关机捷径"（shut-down shortcut）是任意以 EE 为奖励信号的直接学习器都会收敛到的最坏解。

模型化（分数规划的参数化）：依 [1]，对 $D(x) > 0$ 的分数规划 $\max_x N(x)/D(x)$，定义参数化子问题

$$F(q) \;=\; \max_{\mathbf{x}\in\mathcal{X}} \big\{\, N(\mathbf{x}) - q\, D(\mathbf{x}) \,\big\}. \tag{14}$$

定理 4.1 (Dinkelbach 等价性). *(i)* $F(q)$ *在* q *上严格递减；* *(ii)* q^* *为最优比值当且仅当* $F(q^*) = 0$； *(iii) 存在最优解* $x^*(q^*)$ *同时最优化 (14) 与原始分数问题。*

在奖励构造层落地：用 (14) 中的线性目标替换触摸到的 EE 分数项，

$$r_{\text{EE}}(t) \;=\; w_{\text{ee}} \left(\textstyle\sum_k D_k(t) - q^*\, P_{\text{eff}}(t)\right), \qquad w_{\text{ee}} = 8.0, \tag{15}$$

其梯度 $\partial(\Sigma D - q^* P_{\text{eff}})/\partial P = U'(P) - q^*$ 在 q^* 适当（即当前 EE 水平）时于低功率区为**正**——奇点在梯度层面被移除，且线性目标在全 delivery 水平均提供正确方向（无需门控抑制，见 §4.4 (22)）。**模型化要点**：EE 分子取交付比特 ΣD（(10) 口径）而非瞬时和速率 R_{sum}，保证 EE 与交付指标同源。

算法（q^* 在线迭代）：q^* 以 Dinkelbach 外环迭代更新——训练每 $I = 10$ 个 episode，以近 I 期的经验样本平均

$$q^* \;\leftarrow\; \frac{\mathbb{E}\big[\sum_k D_k\big]}{\mathbb{E}\big[P_{\text{eff}}\big]}, \tag{16}$$

再经 anchor EMA 平滑（$\alpha_\eta = 0.2$）——与 Dinkelbach 内层 $F(q) = 0$ 的零搜索异曲同工（期望以训练期样本平均近似，即在线随机逼近版 Dinkelbach 迭代）。不使用外环时退化为内部窗口估计：指数加权累积比率（$\lambda_{\text{EMA}} = 0.99$，约 100 时隙），clip $q^* \in [0.01, 50]$。

接线：(15) 作为 (22) 的首项（EE 分量），并承载门控系数 g_{EE} 与漂移-惩罚中的系数 V（§4.3）。

4.3 Lyapunov 漂移-加-惩罚：约束软约束化

问题：(11b)–(11c) 是长期平均约束，时隙 t 的策略不知道未来的到达与信道，无法逐时隙验证；需要一种把" 长期平均约束" 转化为" 当前时隙可执行信号" 的机制，并保有性能保证。

模型化（虚拟队列软约束化，Neely 框架）：为 (11b)、(11c) 分别定义**交付欠账虚拟队列** Y

与**功率虚拟队列** X：

$$Y[t{+}1] = \max\big\{Y[t] + \underbrace{\delta\, A_{\text{tot}}[t] - D_{\text{tot}}[t]}_{\delta Y},\ 0\big\}, \quad Y_{\max} = 5000, \tag{17}$$

$$X[t{+}1] = \max\big\{X[t] + \eta_X\,\big(P_{\text{tot}}[t] - \bar{P}\big),\ 0\big\}, \quad \eta_X = 0.1,\ X_{\max} = 1000. \tag{18}$$

其中 $A_{\text{tot}} = \sum_k A_k$，$D_{\text{tot}} = \sum_k D_k$，$P_{\text{tot}} = \sum_k P_k$。(17) 中 $\delta Y > 0$ 当且仅当本时隙交付流量低于目标比例 $\delta \cdot A$——欠账累积为 Y；(18) 中 X 在功率超预算时随机增长。两条自对偶关系成立：

引理 4.2 (虚拟队列稳定 $\Leftrightarrow$ 平均约束满足)**.** *若 $\{Y[t]\}$ 均值稳定（$\limsup_{T\to\infty} \mathbb{E}[Y[T]]/T < \infty$），则由 (17) 的递推得 $\frac{1}{T}\sum_t \mathbb{E}\,\text{deliv}[t] \geq \delta - o(1)$（随 T）；同理 X 稳定 $\Leftrightarrow$ (11c) 渐近满足。*

即"*硬阈值 0.98 / 8 W*"*在模型中获得了虚拟队列这一标准身份：它不是实现特设的回撤门，而是平均约束的自然对偶状态。*

队列稳定与二次积压成本：对物理队列取加权积压 $b_k[t] = w_k^{\text{qos}} Q_k[t]/Q_{\max}$（$w^{\text{qos}}$ 为 QoS 类权重），定义增广 Lyapunov 函数与单步漂移

$$L[t] = \frac{1}{2}\sum_k b_k[t]^2 + \frac{1}{2}\Big(\frac{Y[t]}{Y_{\text{ref}}}\Big)^2 + \frac{1}{2}\Big(\frac{X[t]}{X_{\text{ref}}}\Big)^2, \qquad \Delta_L[t] = \mathbb{E}\{L[t{+}1] - L[t] \mid s[t]\}. \tag{19}$$

命题 4.3 (漂移上界)**.** *在到达与速率有界的标准假设下，存在常数 B 使*

$$\Delta_L[t] \;\leq\; B \;+\; \mathbb{E}\Big[\;\sum_k b_k[t]\big(A_k - D_k\big) \;+\; \tfrac{Y[t]}{Y_{\text{ref}}}\big(\delta A_{\text{tot}} - D_{\text{tot}}\big) \;+\; \tfrac{X[t]}{X_{\text{ref}}}\eta_X\big(P_{\text{tot}} - \bar{P}\big)\;\Big|\; s[t]\Big]. \tag{20}$$

其中控制相关的三项分别对应 max-weight 服务 $\sum b_k D_k$（漂移项）、欠账压力吞吐 D_{tot} 与功率对偶 P_{tot}（符号反号后进入奖励）。

漂移-加-惩罚目标即每时隙

$$\min_{\mathbf{a}[t]}\ \Big\{\,\Delta_L[t] \;-\; V\,\mathbb{E}\{\,U[t] \mid s[t]\,\}\Big\}, \qquad U[t] \;:=\; \text{EE 线性化 (15) 与吞吐合计}, \tag{21}$$

即最小化漂移、最大化 V 加权的收益；其控制相关部分（(20) 三项）按负号翻转后即 (22) 的吞吐、欠账与功率对偶分量（命题 4.5）。

算法（漂移-惩罚下降与两层对偶）：(21) 实例化为 (22)；两个实施细节具有标准对应关系：

1. **二次积压成本（LDPTRLQ）：**在漂移-惩罚框架内额外加入**队长期望成本** $-\frac{1}{2}\sum_k b_k[t]^2$（即 Lyapunov 势本身 (19) 的线性缩放），构成"漂移-加-惩罚-加-积压成本"的标准扩张（backlog-penalized drift-plus-penalty）。该扩张直接抑制稳态 $\mathbb{E}[\sum Q^2]$——这正是本文以 $\sum_k Q_k^2/Q_{\max}^2$（`ldptrlq_q_weight`=2.0）作为奖励项的起因：*直接惩罚队积的存在性而非仅惩罚其增长，将稳态队列压到最低*（与 (8) 的有限缓冲口径自洽）。

2. **自适应 V：**权衡系数 V 随队积自适应 $V[t] = V_{\min} + V_{\max}(1 - \bar{Q}[t]/Q_{\max})^{\gamma_V}$（$\gamma_V = 1.5$），低积压时偏向 EE（大 V）、高积压时偏向稳定——等价于对偶权重的内生调度，与 [4, 5] 一致。

定理 4.4 (漂移-惩罚最优性权衡, Neely[3])**.** *若虚拟队列均值稳定，则 (21) 的策略以 $O(1/V)$ 逼近 (11) 的最优长期平均收益，同时虚拟队列积压与对应的平均约束违约以 $O(V)$ 增长。*

实际中 $V = \texttt{lyapunov_V} = 5.0$；该权衡解释了"EE ratio > 1.05 与 delivery 门同时成立" 的可证边界（§5）。与 Lagrangian 对偶（§4.8 约束栈）的关系：λ 惩罚当前约束违反的**水平**，虚拟队列刻画违约的**历史**，二者都以状态增强注入观测。

接线：(17)–(18) 更新产生 $Y, Y_{\text{ref}} = 300$、$X, X_{\text{ref}} = 100$ 的压力项，在 (22) 中分别以吞吐加成项 $w_y(Y/Y_{\text{ref}})\Sigma D$ 与线性功率惩罚 $-w_x(X/X_{\text{ref}})P_{\text{tot}}$ 出现。

4.4 DGLCR：交付门控复合奖励（代理目标组装）

问题：§4.2–§4.3 的构件需组装为**单时隙奖励**，供双层 PPO 使用；同时需防范" 低 delivery 期追省电" 与" 低功率吸引子" 两类学习陷阱。

模型化（代理目标）：定义 DGLCR 复合奖励

$$r(t) = c\Big[\underbrace{g_{\text{EE}}\, V\, w_{\text{ee}}\big(\textstyle\sum_k D_k - q^* P_{\text{eff}}\big)}_{\text{EE 分量 (Dinkelbach 线性)}} + \underbrace{g_{\text{tp}}\, w_{\text{tp}} \sum_k \tfrac{Q_k}{Q_{\max}} w_k^{\text{qos}} D_k}_{\text{max-weight 吞吐}} + \underbrace{w_y \tfrac{Y}{Y_{\text{ref}}} \sum_k D_k}_{\text{交付欠账压力}}\Big] \tag{22}$$
$$- \; c\, w_q \sum_k \frac{Q_k^2}{Q_{\max}^2} - \; c\, w_{\text{ovf}} \sum_k w_k^{\text{qos}} O_k - \; c\, w_x \frac{X}{X_{\text{ref}}} P_{\text{tot}},$$

其中 $c = \texttt{reward_scale} = 0.01$，$V = 5.0,\ w_{\text{tp}} = 3.0,\ w_y = 0.3,\ w_q = 2.0,\ w_{\text{ovf}} = 20.0,\ w_x = 1.0$。

命题 4.5 (代理目标的结构一致性)**.** *在无门控（$g_{\text{EE}} = g_{\text{tp}} = 1$）且去掉 c 的标度下，(22) 恰为漂移-惩罚目标 (21) 的（负号翻转、显式移除外生到达项后）等价形式：EE 分量 $\equiv$ 负惩罚中的收益 U，吞吐份量 $\equiv$ 漂移上界 (20) 中 max-weight 服务的反号，欠账与功率虚拟队列项 $\equiv$ (20) 中对应漂移项的反号，二次积压/溢出项为队积成本扩张。故 DGLCR 是增广系统的单时隙漂移-加-惩罚目标。*

算法（交付门控与可行性切换）：门控系数为 delivery 的 sigmoid 平滑：

$$g_{\text{EE}} = \sigma\big(\kappa_{\text{EE}}(\mathsf{dr} - \mu_{\text{EE}})\big), \quad \mu_{\text{EE}} = 0.935,\ \kappa_{\text{EE}} = 40; \qquad g_{\text{tp}} = 1 + g_{\text{tp}}^{\max}(1 - g_{\text{EE}}), \quad g_{\text{tp}}^{\max} = 4, \tag{23}$$

其中 dr 为 running delivery；dr 低于 μ_{EE} 时 EE 引力被平滑关闭而吞吐推力放大至 5×——这是可行-不可行调度（*feasibility-first*）的连续松弛（CRPO[9] 的软版本）。Dinkelbach 开启时 $g_{\text{EE}} = 1$（线性目标方向本就正确）。惩罚门控（$\mu = 0.96, \kappa = 50$）在低 delivery 期同步抑制 (22) 尾部三项，释放纯吞吐梯度。**约束侧**（见 §4.8）：Lagrangian 对偶乘子 λ 以对偶上升 (28) 施加于 (11b)，并配以词典序梯度投影（EE 梯度投影到交付约束梯度零空间）与 per-user DVQ + CVaR 尾部聚焦。

接线：(22) 即 Worker 的每时隙奖励；Meta 奖励 (27)、内层 PPO 目标 (29) 与各外环在 §4.9 汇总为总学习目标。

4.5 Plackett-Luce 概率解码顺序

问题：SIC 接收机的速率 (4) 取决于解码顺序 π，它是 $K!$ 级排列空间 $\mathcal{S}_K$ 上的决策。$K = 24$ 时 $24! \approx 6.2 \times 10^{23}$，任何直接枚举或非结构化的离散策略都不可学习。

模型化（连续偏好上的 PL 分布）：为每个用户赋予连续的偏好参数（由 Worker 网络的解码序头输出，经 softplus 正数化保证非负）

$$z_k = \mathrm{softplus}(z_k^{\mathrm{raw}}) + 10^{-6} \;=\; \ln(1 + e^{z_k^{\mathrm{raw}}}) + 10^{-6} \;>\; 0, \tag{24}$$

定义排列的 Plackett-Luce 分布与对数似然 [6, 7]

$$\boxed{P(\pi \mid \mathbf{z}) = \prod_{i=1}^{K} \frac{z_{\pi(i)}}{\sum_{j=i}^{K} z_{\pi(j)}}, \quad \log P(\pi \mid \mathbf{z}) = \sum_{i=1}^{K} \Big[\log z_{\pi(i)} - \log \sum_{j=i}^{K} z_{\pi(j)} \Big].} \tag{25}$$

机理：第 i 个被解码的用户按剩余强度成比例抽样——*强信道/高优先级用户更可能先解码*。PL 是以 $O(K)$ 连续参数承载 $\mathcal{S}_K$ 上分布的**最大低秩排列族**，比 $K!$ 维软极大限可行得多。

算法（Gumbel-Top-K 抽样与梯度通道）：直接按 (25) 依序抽样为 $O(K^2)$，且 π 的离散性阻断梯度过离散点。Gumbel-Top-K 给出等价 $O(K \log K)$ 单轮抽样 [8]：

$$\pi \;=\; \mathrm{argsort}^{\downarrow}\big(\log \mathbf{z} + \gamma\big), \qquad \gamma_i \sim \mathsf{Gumbel}(0, 1), \tag{26}$$

即" 对数偏好 + Gumbel 噪声排序"。

命题 4.6 (可微性与无偏性)**.** *(26) 产生的排列服从 (25) 的 PL 分布；对**已实现**排列 π，(25) 的对数似然关于 $\mathbf{z}$ 逐分量可微，其梯度即策略梯度中 π 的（REINFORCE 型）充分统计量——由此"组合顺序决策"以标准 PPO ratio 形式进入优化（§4.8），且该估计**无偏**：Gumbel 噪声仅出现在抽样端，不进入梯度通道。*

实现与工程身份（与其他策略头的差异）：采样在策略网络的 `act()` 内完成，每个 rollout 步重采样；env 仅把排列视为优先级数组（值越小越先解码）转发给两阶段 MMSE-SIC（(4) 在公共/私有流上的实例化）；部署期退化为确定性 $\pi = \mathrm{argsort}^{\downarrow}(\log \mathbf{z})$。三个工程细节值得明确记载：*(a)* 配置项 `pl_temperature`=1.0 声明但**无消费点**——有效温度隐式 1；*(b)* KL 早停仅基于连续动作分量（PL 对数似然量级大方差高，计入将虚高 approx_kl 致每轮早停）；*(c)* PL 头无熵项（排列分布无闭式熵，置零），探索依赖 Gumbel 噪声。

接线：π 作为 4K 维快尺度动作的组成部分联动 (3)–(5) 改变 (4) 中各用户的干扰集合，从而影响服务比特 $\mathbf{D}$、队列 (6) 与 (22)；(25) 的对数似然加入 PPO ratio（§4.8）。Solver-Expert 通道（§4.8）以确定性候选序 {gain-descending, queue-last} 作为教师对齐目标。

4.6 Worker 网络：SA-GAT

快尺度策略为 Self-Attention Graph Worker（SA-GAT），是 (22) 及 PL 头 (25) 的拟合器，解决旧 MLP 骨干中 LN 层稀释 SNR/ε 信号的问题。结构要点：

1. **观测解构：**$11K{+}3$（或 $13K{+}3$，随 QoS/历史开关）观测解构为 per-user token (K, d_{user}) 与全局量（time, snr, eps）；
2. **全局条件（FiLM）：**全局向量仿射调制 token 嵌入，$(\mathrm{snr}, \varepsilon)$ 另复制注入各 token——刻画"全局 SNR 状态如何改变用户级决策"；

3. **自注意力主干**：4 头 ×2 层（隐藏 128）+ FFN + 残差/LN——注意力天然建模过载干扰管理的用户对交互；

4. **per-user 头**：输出 (α, p, d, z) 四元组拼为 $4K$；功率块按 $p_k = K\,\mathrm{softmax}_k(\ell)$（$\ell \in \mathbb{R}^K$ 为功率 logits）归一为**功率份额**（均匀总功率 24 W，极端展宽降至 ~ 8.8 W），z 块进入 PL 头；

5. **Mean-Field critic**：均值池化 + global 残差 $\to V(s)$，注入 QoS 类均值场统计量；

6. **桶专家**：4 个 SNR 桶专家头 episode 级硬路由（独立 lr $= 10^{-4}$），配合硬例挖掘实现 SNR 域分治；

7. **backpressure 先验**（可选）：backlog 驱动功率先验直接加在功率 logits。

4.7 Meta-Controller：分组与组级功率分割

网络（`meta_controller.py`）：per-user meta 特征 $\to$ embed(12$\to$64) $\to$ MHA(4 头) $\to$ FFN；三分支头：分组头（per-user $G = 4$ logits Categorical，温度退火 $\tau : 2.0 \to 0.5$，平衡正则 0.1）、组级 α 头（`group_level_alpha`：mean-pool $\to G$ 维 Gaussian，log-var 初始 -0.5，sigmoid 映射 $[\alpha_{\min}, \alpha_{\max}]$）、critic（mean-pool $\to 1$）。$T_s = 20$ 的慢尺度时序由 Meta 缓冲（FIFO 500，满 $M = 30$ 段触发 PPO 更新）承载。

Slow-scale 目标：Meta 以自有奖励独立训练

$$r^{\mathrm{meta}} = c^{\mathrm{meta}}\Big[\ \overline{\mathrm{EE}} - w^{\mathrm{m}}_{\mathrm{ovf}}\,\overline{\mathrm{OV}} + \mathrm{div}(\mathbf{g}) + w_{\mathrm{bal}}\,\mathrm{bal}(\mathbf{g}) - \beta_\alpha\big(\bar{\alpha} - \alpha^{\mathrm{tgt}}(\mathrm{snr})\big)^2\ \Big], \tag{27}$$

其中 div/bal 为分组多样性/平衡度正则，$c^{\mathrm{meta}} = 0.02$，$\beta_\alpha = 0.3$（warmup 300 episode 后激活）；SNR 条件目标 $\alpha^{\mathrm{tgt}} = \mathrm{clip}\big(0.9 - 0.01\,\mathrm{snr}_{\mathrm{dB}},\, 0.5,\, 0.95\big)$——高 SNR 引导小 α（多公共功率），低 SNR 引导大 α（多私有功率以保解码可靠性）。(27) 与 Worker 目标 (22) 构成两级 POCMDP 的同步收敛（Meta 慢、Worker 快）。

4.8 约束栈与训练算法

约束栈（CMDP 对偶的工程实现）：Lagrangian 对偶乘子 λ（init 5, lr 0.05, cap 100, warmup 200 episode）施加于 (11b)，per-step 信号为其 EMA（$\beta = 0.85$，SLCP-D）；EE 策略梯度向交付约束梯度的零空间投影（词典序安全修正）：

$$\lambda \leftarrow \big[\lambda + \eta_\lambda(\delta - \widehat{\mathrm{deliv}})\big]_+^{\lambda_\cap}, \qquad \mathbf{g} \leftarrow \mathbf{g} - \frac{\mathbf{g}^{\mathsf{T}}\nabla c}{\|\nabla c\|^2}\,\nabla c \quad (c \ge 0,\ \mathbf{g}^{\mathsf{T}}\nabla c < 0), \tag{28}$$

其中 c 为交付约束残差。per-user DVQ（CVaR worst-25% 尾部聚焦）互补强化欠交付用户。

双层 PPO 主循环见算法 1。Worker 内层优化服从标准裁剪代理

$$\mathcal{L}_{\mathrm{PPO}} = \mathbb{E}\Big[\min\big(r_t(\theta)\hat{A}_t,\ \mathrm{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\big)\Big] - c_v\mathcal{L}_{\mathrm{VF}} + c_e\mathcal{H}[\pi_\theta], \qquad r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\mathrm{old}}}(a_t \mid s_t)}, \tag{29}$$

其中 $\log\pi_\theta = \log\pi_\theta^{\mathrm{cont}} + \log P(\pi_t \mid \mathbf{z}_t)$（连续 + PL 联合，(25)），GAE $\hat{A}_t$，KL 早停仅取连续分量（见 §4.5）。行为克隆（BC）预训练将专家演示对齐到连续头与 PL 头：$\mathcal{L}_{\mathrm{BC}} = \mathbb{E}[\|\mathbf{a}_\theta^{\mathrm{cont}} - \mathbf{a}_{\mathrm{expert}}^{\mathrm{cont}}\|^2] - \mathbb{E}[\log P(\pi_{\mathrm{expert}} \mid \mathbf{z}_\theta)]$，随后 PPO 微调 + 衰减锚定（KL-to-BC 信任域、逐步冻结 SFTP）。硬例

挖掘按评估点粒度以逐点 delivery shortfall 加权 + streak 倍增 + 均匀地板重采样训练 SNR；桶专家头按 SNR 桶 episode 级硬路由；Dinkelbach 外层 (16) 每 I=10 episode 更新。

Algorithm 1 两级 POCMDP 在线训练（Worker PPO + Meta PPO + Dinkelbach/Lagrangian 外环 + 硬例挖掘）

Require: 评估网格 $\mathcal{S}$; 慢尺度步长 $T_s = 20$; Meta 阈值 $M = 30$; Dinkelbach 间隔 $I = 10$

初始化 Worker θ、Meta ϕ、对偶 (λ, q^*)、专家演示缓存与硬例权重 $\omega_s \leftarrow \mathbf{1}$
for each episode e=1, . . . , E **do**
  硬例挖掘：$s\sim$ 按 ω_s（逐点 shortfall × streak 倍增 + 地板）采样 SNR; env.reset
  桶路由 → 专家头; Meta 决策 → g_k, α_g（`set_group_ids/set_split_mask`）
  for step t=1, . . . , T **do**
    Worker → $(\alpha, p, d, \mathbf{z})$; $\pi \sim \mathsf{PL}(\mathbf{z})$（(26)）; 组装 4K 动作
    env.step: (3)–(5) 两阶段 MMSE-SIC → $\{R_k, D_k, O_k, P\}$ → (6)
    Lyapunov 控制器更新 Y, X（(17)–(18)）; 计算 (22); buffer.add $((s, a, \log P(\pi|z), r, s'))$
    if $t \bmod T_s = 0$ **then**
      闭合 meta 段 → meta_buffer; ϕ 重新决策
    end if
  end for
  Worker PPO 更新 (29)（clip+GAE+KL 早停 + 熵 +BC 锚定）; Meta 缓冲 $\geq M$ 段时更新 (27)
  if $e \bmod I = 0$ **then**
    $q^* \leftarrow \mathbb{E}[\Sigma D]/\mathbb{E}[P_{\text{eff}}]$（(16), anchor α_η=0.2 EMA）
  end if
  λ 对偶上升 (28); ω_s 按逐点 delivery shortfall EMA
end for

4.9 最终模型综合（完整总结）

至此可将 (11) 的求解模型完整组装为**五层描述**——这是" 算法设计后的最终模型"，也是论文 §III 的骨架：

(a) 模型五元组。 系统模型 $\mathcal{M} = (\mathcal{S}, \mathcal{O}, \mathcal{A}, \{\mathcal{C}_i\}, r)$：

- **状态** $\mathcal{S}$（对策略不可直接观测，见 $\mathcal{O}$）：信道/CSI 误差、队列 $\mathbf{Q}$、到达 $\mathbf{A}$、虚拟队列 (Y, X)、对偶 (λ, q^*)、Meta 段累计统计；
- **观测** $\mathcal{O}$：per-user 块 + global 块共 $11K$+3（H 历史可选），State-Augmentation 等维注入 (λ, Y, q^*)；
- **动作：** 快尺度 $\mathbf{a} \in [0, 1]^{3K} \times \mathbb{R}^K$：$(\mathbf{p}, \mathbf{d}, \mathbf{z})$（功率份额、drain、PL 偏好），$\pi$ 由 (26) 导出；慢尺度 $\mathbf{a}^{\text{m}} = (g, \alpha) \in \{0..3\}^K \times [\alpha_{\min}, \alpha_{\max}]^G$，以覆盖方式压制快尺度 α 块（动作空间去冗余）；

- **约束** $\{\mathcal{C}_i\}$：(11b)（$\to Y+\lambda+$ DVQ）、(11c)（$\to X$）、(11d)（$\to$ LDPTRLQ + 溢出项）；
- **奖励**：Worker (22)（DGLCR 代理目标），Meta (27)。

(b) 每次时隙的执行链。 $s[t] \xrightarrow[\text{Worker}]{} \mathbf{a}[t] \Rightarrow \pi \sim \mathsf{PL} \Rightarrow$ MMSE-SIC $\Rightarrow (D,O,P) \Rightarrow (Q,Y,X)$ 更新 $\Rightarrow r[t] \xrightarrow[\text{PPO}]{(29)}$ 梯度；每 T_s 步插入 Meta 决策链 (27)。

(c) 多时间尺度学习目标（总目标）。

$$\max_{\theta}\ J_W(\theta), \qquad J_W=\mathbb{E}_\theta\Big[\sum_t \gamma^t\, r[t]\Big] \quad \text{(Worker PPO, (29))}, \tag{30}$$

$$\max_{\phi}\ J_M(\phi), \qquad J_M=\mathbb{E}_\phi\Big[\sum_m \gamma^m\, r^{\text{meta}}[m]\Big] \quad \text{(Meta PPO, (27))}, \tag{31}$$

$$\text{外环：}\quad q^*\ \text{按 (16)},\quad \lambda\ \text{按 (28)},\quad \omega_s\ \text{按硬例挖掘 EMA.} \tag{32}$$

（(30) 中各外环的分离性与 (16)/(28) 的总计步进，使 (11) 的" 目标—约束—动作域" 三族元素均有明确的实现回执，见表 1。）

(d) 决策时钟。 慢尺度 $T_s=20$；快尺度 1；Dinkelbach 外环 $I=10$ ep；Lagrangian 对偶每 ep；Meta 参数更新每 M=30 个 meta 段；硬例挖掘权重每 ep EMA。多时间尺度的一致性由总目标 (30) 与各级更新时钟协同定义。

(e) 与实现的关系（供代码溯源，不进入论文正文）。 实现把 (11d) 的有限缓冲、(11b) 的目标 δ、(11c) 的 $\bar{P}$ 以字面常量出现；其与虚拟队列的对应见引理 4.2 及附录 B——即" 硬约束" 在建模口径上是平均约束的虚拟队列软约束化，在实现口径上是其逐字面的有限缓冲对偶。

5 数值评估

5.1 口径与设置

按 §3.5.2 评估：7 点 SNR 网格、imperfect CSI、每点 50 episode；比较基线为经典 SDMA、NOMA 与等功率方案（并纳入单时间尺度 Lyapunov DRL 对照 LDPTRLQ）。训练设置与超参数见附录 A。

5.2 全网格基准

表 2 给出逐点交付率 / 发射功率 / 平均队列。策略在全部 7 点达标，字典序 score 为

$$\text{score}=[\,7,\ 0.9519,\ -8.3971,\ 1.0804\,], \tag{33}$$

平均功率 13.84 W（< SDMA），聚合 EE ratio 1.0804（> 1.05）。优势在深过载高 SNR 区最大：30 dB 交付 0.888，SDMA / NOMA / 等功率分别为 0.664、0.581、0.601；且其发射功率约为固定功率基线的 $\sim$ 一半。

每点门限裁定（(12)）：0 dB（$0.886 \geq 0.856$ 且 $2.84 \leq 1.1 \times 3.46$）$\to$ 达标；其余各点同理，7/7 达标。

表 2: 逐点交付率 / 发射功率 (W) / 平均队列（50 ep/点，imperfect CSI；数据源 `docs/paper/main.tex`）。

SNR (dB)	本方案 (PPO-RSMA)	SDMA	NOMA	EqualPower
0	**0.886**/13.72/2.84	0.856/14.69/3.46	0.836/17.35/4.01	0.791/24.00/4.94
5	**0.989**/14.39/0.43	0.979/13.70/0.68	0.970/17.35/0.92	0.943/24.00/1.53
10	**0.993**/14.59/0.69	0.961/15.02/2.28	0.947/17.35/3.10	0.915/24.00/4.62
15	**0.991**/13.71/1.91	0.887/15.12/11.42	0.839/17.35/15.54	0.824/24.00/15.48
20	**0.974**/13.39/7.20	0.795/14.62/22.39	0.715/17.35/27.40	0.726/24.00/25.50
25	**0.942**/13.59/16.08	0.724/14.64/28.76	0.636/17.35/33.07	0.658/24.00/31.80
30	**0.888**/13.52/29.63	0.664/14.87/34.47	0.581/17.35/36.83	0.601/24.00/37.27

5.3 谱系、种子稳健性与预注册微调

谱系: 纯 BC（8,000 专家演示）$[7, 0.9441, -9.3929, 1.0753] \xrightarrow{\text{SFTP(P=PPO+BC 锚定)}}$ champion $[7, 0.9519, -8.3971, 1.0804]$（零 guard 回滚）——PL 头克隆（(25) NLL）即达全网格，验证" 连续 + 排列联合克隆" 可行性。

种子稳健性: 种子 42–46 best-guard 交付 $\{0.9503, 0.9414, 0.9519, 0.9526\}$，均值 0.9496、sd 0.0047、极差 0.0112（预注册降级触发阈 0.012 未触发）——champion 是均值带 0.9496 ± 0.0047 中的一抽，单种子样本下 $\delta \lesssim 0.005$ 的差异低于种子分辨率。

预注册微调（M5.1–M5.3）: 五项单变量干预（释放 lr / KL 信任域 / 强锚定 / 采样分布）score 均 0.9446–0.9474，落入冠军种子带——当前样本量下**无处理效应**，协议贡献按" 种子稳健运行点 0.9496 ± 0.0047" 报告，不宣称单项机制因果性。

5.4 模型基每时隙优化器上界与讨论

无学习策略的 **DiffOpt**（每时隙对功率 logits 跑 25 步 Adam + 解码序候选择优，surrogate 镜像 (22)，可微引擎与不可变实现 float64 一致性 atol $= 10^{-9}$）在每一点超越学习策略：均值交付 0.9574 vs. 0.9519（+0.0055，超出 ±0.005 种子带）、均值队列 7.36 vs. 8.40，且全部 7 门达标。其因果变体（surrogate 只用 $\hat{\mathbf{H}}$）与 oracle-CSI 变体逐点一致（$\max|\Delta| \le 0.001$），排除 CSI 泄漏——即**无模型在线优化器可严格支配当前学习策略**。这一上界为 §4.9 的" 代理目标可学性上界" 给出量化证据，亦构成 §6 中 ExIt 闭环、策略-上界差距收敛的主要后续方向。

6 结论与展望

本报告给出过载上行 RSMA-MU-MIMO 上 EE 在线优化的完整模型与算法框架。最终模型（§4.9）是一个**两级受约束部分可观 MDP**：慢尺度 Meta 决策分组与组级分割比，快尺度 SA-GAT Worker 决策功率份额、drain 与 PL 解码顺序；奖励经 Dinkelbach 线性化（分数目标 → 线性）、Lyapunov 虚拟队列（平均约束 → 稳定性）、二次积压成本（缓冲 → 队期望值成本）三级转化组装为单时隙 DGLCR 代理目标；训练由双层 PPO（(29)）配 Dinkelbach 外环 (16)、Lagrangian 对偶

(28) 与硬例挖掘构成。在 7 点网格上以 $[7, 0.9519, -8.3971, 1.0804]$ 全部达标，跨种子 $\sigma \approx 0.005$，消融无处理效应，均支持” 成绩来自模型结构而非超参运气” 的弱论断。

三条可泛化的建模洞见（供论文讲故事使用）：

1. **分数 → 线性**：EE 分数目标经 Dinkelbach 参数化等价线性化，$P \to 0$ 奇点从梯度层面移除——比任何正则化/惩罚都更结构。

2. **硬约束 → 平均约束的虚拟队列**: 交付率/功率的” 硬阈值” 在模型中都是平均约束 (11b)–(11c) 的虚拟队列软约束化（引理 4.2），附带 $O(1/V)/O(V)$ 权衡（定理 4.4）——叙述口径与理论保证齐备。

3. **组合 → 概率**：解码顺序以 $O(K)$ 参数承载 $K!$ 级分布（PL），Gumbel-Top-K 保证无偏可微抽样（命题 4.6）——SIC 顺序从启发式上升为可学习决策。

展望：(i) 以 DiffOpt 上界（§5.4）为教师回归 ExIt 闭环（BC → PPO → 衰减锚定），量化” 策略-上界差距收敛”；(ii) 功率预算 $\bar{P}$ 由静态常数推广为每 SNR 桶的动态水平（即虚拟队列目标的自适应化）；(iii) PL 解码顺序引入 common/private 两级联合排列（两倍排列空间的低秩乘积建模）；(iv) 以种子带宽 $n = 5$ 补齐预注册微调的多种子因果裁定。

A 核心参数表

B 实现位置对照（代码溯源，不进入论文正文）

C 符号表

$\mathbf{H}, \hat{\mathbf{H}}$ 实际/估计信道（$N_r \times K$）；π SIC 解码顺序；α_k 功率分割比；$\mathbf{p}$ 功率份额；$\mathbf{d}$ drain 比例；$\mathbf{z}$ PL 偏好；D_k, R_k 交付/速率比特；A_k 到达；$Q_k, Q_{\max}$ 队列；Y, X 虚拟队列；q^* Dinkelbach 参数；λ Lagrangian 乘子；$\delta = 0.98$ 交付目标；$\bar{P} = 8\,\mathrm{W}$ 功率预算；g 分组；$\mathcal{S}_K$ 排列空间。

参考文献

[1] Dinkelbach W. On nonlinear fractional programming[J]. Management Science, 1967, 13(7): 492–498.

[2] Shen K, Yu W. Fractional programming for communication systems, Part I/II[J]. IEEE Trans. Signal Process., 2018.

[3] Neely M J. Stochastic Network Optimization with Application to Communication and Queueing Systems[M]. Morgan & Claypool, 2010.

[4] Li L, et al. Lyapunov-assisted deep reinforcement learning for network optimization[J]. IEEE Trans. Commun., 2021.

[5] Chen M, et al. Lyapunov-assisted deep reinforcement learning for wireless resource allocation[J]. IEEE Wireless Commun. Lett., 2019.

[6] Plackett R L. The Analysis of Permutations[J]. Applied Statistics, 1975, 24(2): 193–202.

[7] Luce R D. Individual Choice Behavior: A Theoretical Analysis[M]. Wiley, 1959.

[8] Kool W, van Hoof H, Welling M. Stochastic Beams and Where to Find Them: The Gumbel-Top-k Trick for Sampling Sequences Without Replacement[C]//ICML 2019.

[9] Xu T, Liang Y, Lan G. CRPO: A New Approach for Safe Reinforcement Learning with Convergence Guarantee[C]//ICML 2021.

[10] Sutton R S, Precup D, Singh S. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning[J]. Artificial Intelligence, 1999, 112(1–2): 181–211.

[11] Zhang M, et al. PPO-based resource allocation for RSMA in overloaded uplink[J]. IEEE, 2023.

表 3: 关键参数默认值（权威 = `src/config.py`）。

域	参数	默认值
网络/信道	$K/N_r/N_t$	24 / 16 / 2
	T / $Q_{\max}$ / $P_k^{\max}$	200 / 100 / 1.0 W
	ρ (AR(1))	0.9
	$\varepsilon_{\text{floor}}$ / β	0.01 / 0.0
功耗	η_{PA} / P_{circ}	0.35 / 5.0 W
	P_{floor} (ee)	3.0 W
	$\bar{P}$ (功率预算)	8.0 W
Dinkelbach	w_{ee}	8.0
	q^* 范围	$[0.01, 50]$, 外环 I=10 ep
	anchor α_η	0.2
Lyapunov/奖励	V(lyapunov) / 自适应 $V_{\min\,..\,\max}$	5.0 / $[0.3, 5.0]$
	Y_{ref} / X_{ref}	300 / 100
	w_q / w_{ovf} / w_{tp} / w_y / w_x	2 / 20 / 3 / 0.3 / 1.0
	c (reward scaler)	0.01; 门 mid/κ = 0.935/40、0.96/50
PL	强度	$z = \text{softplus}(z^{\text{raw}}) + 10^{-6}$
	采样	$\text{argsort}^{\downarrow}(\log z + G)$, $G \sim \mathsf{Gumbel}(0, 1)$
	似然	闭合 $\log P(\pi \mid z)$ (解析, 梯度经 z)
	温度	隐式 τ=1（`pl_temperature` 无消费点）
分层	T_s / G / M	20 / 4 / 30
	α 域	$[0.1, 0.95]$, τ : 2.0→0.5
	β_α (SNR 条件引导)	0.3 (warmup 300 ep)
PPO	clip / γ / GAEλ / epochs / batch	0.2 / 0.99 / 0.95 / 8 / 64
	rollout / LR(actor/critic/logσ)	2048 / $3e{-}4$/$1e{-}3$/$1e{-}3$
	target KL (早停)	0.02 (仅连续分量)

表 4: 机制 → 实现位置对照表。

机制	实现位置
PL 采样/似然	src/models/actor_critic.py:42--83, 809--815
PL 强度	actor_critic.py:790, 809（softplus+1e-6）
KL 早停仅连续分量	src/training/ppo.py:894--900
解码序 buffer (int64)	src/training/buffer.py:48--52
env 拆包/转发	src/env/rsma_env.py:732--736, 781--794
两阶段 MMSE-SIC	src/env/rate_calc.py:284--414（不可变）
DGLCR 奖励	src/optimization/lyapunov.py:497--632
虚拟队列 Y/X	lyapunov.py:499--627 (λ 更新 main.py)
DH 外层	main.py（每 10 ep, dinkelbach_outer_update）
DGLCR 门控	lyapunov.py:575--601
Solver-Expert	src/optimization/solver_expert.py:107--114, 269--314
可微引擎	src/optimization/diff_engine.py:81--86, 131--155